

UNIVERSIDADE PERNAMBUCO
CURSO DE EXTENSÃO EM CIÊNCIA DOS DADOS E ANALYTICS

ESTATÍSTICA COMPUTACIONAL
PROF. DRA. ROBERTA FAGUNDES

Recife/PE
2021

Projeto Final de Disciplina
Aluno: Breno Luiz Santos Soares

1. O Projeto:

Trata-se da análise estatística de dados da plataforma UCI, a base é denominada “Combined Cycle Power Plant Data Set”, encontrada no seguinte endereço da internet <https://archive.ics.uci.edu/ml/datasets/Combined+Cycle+Power+Plant>.

O projeto tem início com a elaboração de um problema vinculado à base de dados com que se trabalha.

Objetiva-se aplicar os conhecimentos adquiridos em sala de aula, inclusive com a utilização da linguagem R, de tal forma que se entenda melhor o problema e que se tenha maior criticidade na análise dos resultados.

2. Relatório:

2.1 Justificativa:

Uma usina de ciclo combinado (UCB) é composta por turbinas de gás, turbinas de vapor e geradores à vapor de recuperação de calor. Em uma UCB, a eletricidade é gerada por turbinas de gás e a vapor, que são combinadas em um ciclo, e é transferida de uma turbina para outra. O número de variáveis que possuem influência na produção de energia de uma UCB são várias, tais como temperatura, pressão, umidade, dentre outras.

O objetivo desse trabalho é estimar quais são as melhores condições para a produção de energia elétrica em uma UCB. Para tanto, será utilizado o modelo de regressão linear, preferencialmente com variáveis cuja correlação com o valor da produção de energia seja maior.

Por fim, serão comparados alguns modelos utilizando-se testes de hipótese, para ao final tentar concluir qual condição seria a melhor e teria a menor redução na produção de energia elétrica de uma UCB.

2.2 Base de Dados:

Cada registro da base de dados é composto de cinco variáveis, que são:

- Temperatura (AT)
- Pressão ambiente (AP)
- Umidade relativa (RH)
- Vácuo de exaustão (V)
- Produção energia (PE)

2.3 Análise Estatística:

A programação em R será utilizada para realizar a análise exploratória, formulação de hipóteses e análise dos resultados. O código em R será mostrado em itálico, para diferenciar-se das demais colocações. As saídas do programa, quando relevantes, também serão mostradas.

#Abrir a base de dados:

```
getwd()  
  
setwd("C:\Users\BSOARES\Documents\CCPP")  
  
base = read.csv2("base.csv", header=TRUE, sep=",")
```

#Ver como estão os dados, quais os seus tipos:

```
head(dados)
```

	AT	V	AP	RH	PE
1	14.96	41.76	1024.07	73.17	463.26
2	25.18	62.96	1020.04	59.08	444.37
3	5.11	39.40	1012.16	92.14	488.56
4	20.86	57.32	1010.24	76.64	446.48
5	10.82	37.50	1009.23	96.62	473.90
6	26.27	59.44	1012.23	58.77	443.67

```
str(dados)
```

```
'data.frame': 9568 obs. of 5 variables:  
 $ AT: num 14.96 25.18 5.11 20.86 10.82 ...  
 $ V : num 41.8 63 39.4 57.3 37.5 ...  
 $ AP: num 1024 1020 1012 1010 1009 ...  
 $ RH: num 73.2 59.1 92.1 76.6 96.6 ...  
 $ PE: num 463 444 489 446 474 ...
```

#Identificar a amplitude, média e mediana para cada uma das variáveis:

```
> summary(base$AT)  
  
Min. 1st Qu. Median Mean 3rd Qu. Max.  
1.81 13.51 20.34 19.65 25.72 37.11
```

```
> summary(base$V)  
  
Min. 1st Qu. Median Mean 3rd Qu. Max.  
25.36 41.74 52.08 54.31 66.54 81.56
```

```
> summary(base$AP)  
  
Min. 1st Qu. Median Mean 3rd Qu. Max.  
992.9 1009.1 1012.9 1013.3 1017.3 1033.3
```

```
> summary(base$RH)  
  
Min. 1st Qu. Median Mean 3rd Qu. Max.  
25.56 63.33 74.97 73.31 84.83 100.16
```

```
> summary(base$PE)  
  
Min. 1st Qu. Median Mean 3rd Qu. Max.  
420.3 439.8 451.6 454.4 468.4 495.8
```

A partir dos resultados obtidos acima, é possível observar que todas as variáveis possuem média muito próxima da mediana, sugerindo uma distribuição simétrica. Pode-se observar que na variável umidade relativa (RH) que a maior parte dos dados está concentrada em valores maiores

#Calcular a variância e desvio padrão para cada uma das variáveis:

```
> var(base$AT)
```

```
[1] 55.53936
```

```
> sd(base$AT)
```

```
[1] 7.452473
```

```
> var(base$V)
```

```
[1] 161.4905
```

```
> sd(base$V)
```

```
[1] 12.70789
```

```
> var(base$AP)
```

```
[1] 35.26915
```

```
> sd(base$AP)
```

```
[1] 5.938784
```

```
> var(base$RH)
```

```
[1] 213.1678
```

```
> sd(base$RH)
```

```
[1] 14.60027
```

```
> sd(base$PE)
```


```
[1] 17.06699
```

```
> var(base$PE)
```


```
[1] 291.2823
```

#Plotar o melhor gráfico para cada uma das variáveis:


```
> hist(base$AT, labels = T, col = "green", main = "Temperatura", xlab = "TEMPERATURA",  
ylab = "Frequências Absolutas")
```




```
> hist(base$PE, labels = T, col = "yellow", main = "PRODUÇÃO DE ENERGIA", xlab =  
"Energia", ylab = "Frequências Absolutas")
```



```
> hist(base$RH, labels = T, col = "blue", main = "Umidade", xlab = "UMIDADE RELATIVA",
ylab = "Frequências Absolutas")
```




```
> hist(base$AP, labels = T, col = "red", main = "Pressão", xlab = "PRESSÃO ATMOSFÉRICA", ylab = "Frequências Absolutas")
```



A partir da análise dos gráficos acima, é possível observar que a variável que mais se aproxima de uma distribuição normalizada é a pressão atmosférica (AP), além disso, pode-se observar que a variável umidade relativa (RH) possui maior parte de seus registros concentrados em valores acima da média.


#Plotar o boxplot para todas as variáveis quantitativas:

```
> boxplot(base$AT)
```




Como foi visto anteriormente, pode-se observar que a mediana da variável temperatura (AT) se aproxima de 20.

```
> boxplot(base$RH)
```




Podemos observar que a mediana está próxima de 80, como foi calculado anteriormente e a sugestão da existência de outliers perto de 50.

```
> boxplot(base$PE)
```




Pode-se observar que a mediana está próxima de 450, como foi visto anteriormente e os dados possuem uma distribuição quase simétrica.

```
> boxplot(base$V)
```



Como calculado anteriormente, pode-se observar que a mediana está próxima de 50 e esse gráfico sugere que os dados possuem uma distribuição quase simétrica.

```
> boxplot(base$AP)
```




Pode-se observar que nesse gráfico é clara a presença de outliers acima de 1030 e abaixo de 1000 e como visto anteriormente a mediana encontra-se próxima de 1010.

#Calcular a correlacão e plotar o gráfico de dispersão:

```
> cor(base$PE, base$V)
```

```
[1] -0.8697803
```

```
> plot(base$PE, base$V)
```




Pode-se observar que a correlação da produção de energia com o vácuo é negativa e indica que as duas variáveis se movem em direções opostas, porém como a correlação está próxima de -1 é possível afirmar que as duas variáveis possuem uma relação forte. Ainda é possível observar no gráfico a presença de outliers.

```
> cor(base$PE, base$AP)
```

```
[1] 0.518429
```

```
> plot(base$PE, base$AP)
```




Pode-se observar que a correlação entre a produção de energia e a pressão atmosférica não é tão forte e ainda podemos observar no gráfico uma grande presença de outliers depois dos 1030 e antes de 1000, como foi visto anteriormente no boxplot da variável.

```
> cor(base$PE, base$RH)
```

```
[1] 0.3897941
```

```
> plot(base$PE, base$RH)
```




A correlação da produção de energia com a umidade relativa foi ainda mais fraca que a da pressão atmosférica.

```
> cor(base$PE, base$AT)
```

```
[1] -0.9481285
```

```
> plot(base$PE, base$AT)
```




Observa-se que a correlação entre a produção de energia e a temperatura é fortíssima e negativa, se aproximando bastante de -1. Ou seja, isso indica que a temperatura possui uma grande influência na produção de energia em UCB.


#Formular um problema de regressão e analisá-lo como também discuti-lo:

Como foi possível observar no gráfico anterior, pelo cálculo das correlações e dos gráficos de dispersão, percebe-se que a correlação da variável independente com as variáveis dependentes metade são fracas e a outra metade é forte. A correlação mais forte foi com a variável temperatura, como se era de esperar, e a mais fraca foi com a pressão. Porém, será utilizado o método de regressão linear para estimar os valores de produção de energia: primeiramente com a variável temperatura, cuja correlação foi mais forte e depois, com todas as variáveis quantitativas dependentes, para ao final comparar os resultados.

#Regressão Linear Simples:

```
> #MAIOR CORRELAÇÃO  
> reg1 = lm(base$AT~base$PE)  
> a1 = reg1$coefficients[1]  
> b1 = reg1$coefficients[2]  
> ajustados1 = reg1$fitted.values  
> erro1 = base$AT - ajustados  
> hist(erro, main = "Histograma dos Residuais", ylab = "Residuais")  
> plot(base$PE, base$AT, xlab = "Produção de Energia", ylab = "Temperatura")  
> abline(reg1, col = "green")
```





Como podemos observar a correlação é altíssima entre a produção de energia e a temperatura, isso apenas confirma o que era esperado, pois em turbinas de gás e a vapor a temperatura é uma variável que possui uma grande influência no processo de funcionamento normal delas. Ainda é possível observar que quanto menor a temperatura maiores são os níveis de produção de energia elétrica, indicando um melhor funcionamento das turbinas da UCB.

```

> #CORRELAÇÃO MEDIANA

> reg2 = lm(base$AP~base$PE)

> a2 = reg2$coefficients[1]

> b2 = reg2$coefficients[2]

> ajustados2 = reg2$fitted.values



> erro2 = base$AP - ajustados

> hist(erro, main = "Histograma dos Residuais", ylab = "Residuais")

```

```
> plot(base$PE, base$AP, xlab = "Produção de Energia", ylab = "Pressão")
```

```
> abline(reg2, col = "red")
```



Como pode-se observar uma grande presença de outliers entre as variáveis produção de energia e pressão atmosférica, além disso a correlação entre as duas está em patamar médio, indicando que a variável não possui tanta influência no processo de produção de energia, esse fato está de acordo com o que se diz na literatura pois a pressão atmosférica não tem ligação direta no processo principalmente de turbinas.

```
> #MENOR CORRELAÇÃO

> reg3 = lm(base$RH~base$PE)

> a3 = reg3$coefficients[1]

> b3 = reg3$coefficients[2]


> ajustados3 = reg3$fitted.values


> erro3 = base$RH - ajustados

> hist(erro, main = "Histograma dos Residuais", ylab = "Residuais")

> plot(base$PE, base$RH, xlab = "Produção de Energia", ylab = "Umidade Relativa")

> abline(reg3, col = "blue")
```





Entre as variáveis a que possui menor correlação com a variável produção de energia é a variável umidade relativa, que também é possível observar que existe um grande número de outliers e a umidade não tem praticamente nenhuma influência na produção de energia elétrica na UCB.

#Regressão linear múltipla, com todas as variáveis quantitativas independentes:

> #REGRESSÃO MULTIPLA

> regressao_multipla = lm(base\$PE~base\$AT+base\$RH+base\$AP)

> regressao_multipla\$coefficients[1]

(Intercept)

490.3237

> regressao_multipla\$coefficients[2]

base\$AT

-2.377708

> regressao_multipla\$coefficients[3]

base\$RH

-0.2038319

> regressao_multipla\$fitted.values


1 2 3 4 5 6 7 8 9 10 11 12 13

465.8220 444.2916 485.0736 450.7353 470.5093 441.5649 462.9338 480.1001 473.0311

473.7511 457.8449 455.0910 440.9573


> erro = base\$PE - regressao_multipla\$fitted.values


> hist(erro, main = "Histograma de Erros", ylab = "Frequência")



Podemos observar no histograma que o erro possui uma distribuição normal, indicando que os erros estão muito próximos.

#Realizar teste de normalidade usando boxplot, histograma e shapiro.test, discutir os resultados:





Pelo histograma, é possível observar que os dados dos valores de produção de energia não seguem uma distribuição normal. Vamos aplicar o teste de aderência de Shapiro para chegarmos a uma conclusão a esse respeito.

```
> library(caret)
```

#Modelo 1

```
> ModeloAjustado2 = c(0)
```

```
> ErroAbsoluto2 = c(0)
```

```
> ErroMedioQuadratico2 = c(0)
```

```
> for (i in 1:50){
```

```
+ #Criando os índices para Holdout
```

```
+ ind = createDataPartition(base$PE,p = 2/3, list = FALSE)
```

```
+ #Dividindo em Treino e Teste
```

```

+ train.data <- base[ind, ]
+ test.data <- base[-ind, ]
+ # Construção do Modelo de Regressão
+ modelo2 = lm(base$PE~base$AT+base$V+base$AP+base$RH, data = train.data)
+ # Calculo do Valor predito
+ ValoresPreditos2 = modelo2$coefficients[1] + modelo2$coefficients[2]*test.data$AT +
  modelo2$coefficients[3]*test.data$V      +     modelo2$coefficients[4]*test.data$AP      +
  modelo2$coefficients[5]*test.data$RH
+ ModeloAjustado2 [i] = c(R2(ValoresPreditos2, test.data$PE))
+ ErroAbsoluto2 [i] = c(MAE(ValoresPreditos2, test.data$PE))
+ ErroMedioQuadratico2 [i] = c(RMSE(ValoresPreditos2, test.data$PE))
+ }

> mean(ModeloAjustado2)
[1] 0.9288119

> mean(ErroAbsoluto2)
[1] 3.623074

> mean(ErroMedioQuadratico2)
[1] 4.556838

```

#Modelo 2

```
> ModeloAjustado3 = c(0)

> ErroAbsoluto3 = c(0)

> ErroMedioQuadratico3 = c(0)

> for (i in 1:50){

+  #Criando os índices para Holdout

+  ind = createDataPartition(base$AT,p = 2/3, list = FALSE)

+  #Dividindo em Treino e Teste

+  train.data <- base[ind, ]

+  test.data <- base[-ind, ]

+  # Construção do Modelo de Regressão

+  modelo3 = lm(base$PE~base$AT+base$V, data = train.data)

+  # Calculo do Valor predito

+ ValoresPreditos3=modelo3$coefficients[1]+modelo3$coefficients[2]*test.data$AT+model
o3$coefficients[3]*test.data$V

+  #Métricas para Avaliar o modelo

+  ModeloAjustado3 [i] = c(R2(ValoresPreditos3, test.data$PE))

+  ErroAbsoluto3 [i] = c(MAE(ValoresPreditos3, test.data$PE))

+  ErroMedioQuadratico3 [i] = c(RMSE(ValoresPreditos3, test.data$PE))

+ }

> mean(ModeloAjustado3)

[1] 0.9150037

> mean(ErroAbsoluto3)

[1] 3.926851

> mean(ErroMedioQuadratico3)
```

```
[1] 4.971302
```

#Modelo 3

```
> ModeloAjustado4 = c(0)

> ErroAbsoluto4 = c(0)

> ErroMedioQuadratico4 = c(0)

> for (i in 1:50){

+  #Criando os índices para Holdout

+  ind = createDataPartition(base$AP,p = 2/3, list = FALSE)

+  #Dividindo em Treino e Teste

+  train.data <- base[ind, ]

+  test.data <- base[-ind, ]

+  # Construção do Modelo de Regressão

+  modelo4 = lm(base$PE~base$AT, data = train.data)

+  # Calculo do Valor predito

+  ValoresPreditos4 = modelo4$coefficients[1] + modelo4$coefficients[2]*test.data$AT

+  #Métricas para Avaliar o modelo

+  ModeloAjustado4 [i] = c(R2(ValoresPreditos4, test.data$PE))

+  ErroAbsoluto4 [i] = c(MAE(ValoresPreditos4, test.data$PE))

+  ErroMedioQuadratico4 [i] = c(RMSE(ValoresPreditos4, test.data$PE))

+ }

> mean(ModeloAjustado4)

[1] 0.8979915

> mean(ErroAbsoluto4)
```

```
[1] 4.299107
```

```
> mean(ErroMedioQuadratico4)
```

```
[1] 5.445082
```

```
> media_erro2 = mean(ErroAbsoluto2)
```

```
> media_erro3 = mean(ErroAbsoluto3)
```

```
> media_erro4 = mean(ErroAbsoluto4)
```

```
> media_erro2
```

```
[1] 3.623074
```

```
> media_erro3
```

```
[1] 3.926851
```

```
> media_erro4
```

```
[1] 4.299107
```

Foram criados 3 modelos:

- O modelo2 leva em consideração todas as variáveis independentes quantitativas;
- O modelo3 leva em consideração as 2 variáveis independentes quantitativas com maior correlação com a variável dependente;
- O modelo4 leva em consideração apenas a variável independente quantitativa com maior correlação com a variável dependente.

Como se percebe após o cálculo dos vetores de erro num loop de 50 repetições, a média do erro do modelo 1 é a menor, o que torna esse modelo com mais variáveis teoricamente o "menos ruim". Mas isso é apenas uma hipótese que será testada mais adiante.

```
> shapiro.test(ErroAbsoluto2)
```

Shapiro-Wilk normality test

data: ErroAbsoluto2

W = 0.95949, p-value = 0.0846

```
> shapiro.test(ErroAbsoluto3)
```

Shapiro-Wilk normality test

data: ErroAbsoluto3

W = 0.98063, p-value = 0.5787

```
> shapiro.test(ErroAbsoluto4)
```

Shapiro-Wilk normality test

data: ErroAbsoluto4

W = 0.97661, p-value = 0.4194

Pelo teste de normalidade de Shapiro, em todos os modelos os dados seguem distribuição normal, pois o p-value foi superior a 0.05.

#Formular teste de hipótese e ANOVA, discutir os resultados:

#Utilizando o Teste t de Student:

```
> t.test(ErroAbsoluto2, ErroAbsoluto3, alternative = "two.sided")
```

Welch Two Sample t-test

data: ErroAbsoluto2 and ErroAbsoluto3

t = -35.764, df = 96.707, p-value < 2.2e-16

alternative hypothesis: true difference in means is not equal to 0

95 percent confidence interval:

-0.3206360 -0.2869183

sample estimates:

mean of x mean of y

3.623074 3.926851

Como p-value deu menor que 0.05, então rejeita-se H0 que os erros 2 e 3 são iguais, acatando-se H1 que são diferentes. Em sendo diferentes, vejamos qual dos dois é menor:

```
> t.test(ErroAbsoluto2, ErroAbsoluto3, alternative = "less")
```

Welch Two Sample t-test

data: ErroAbsoluto2 and ErroAbsoluto3

t = -35.764, df = 96.707, p-value < 2.2e-16

alternative hypothesis: true difference in means is less than 0

95 percent confidence interval:

-Inf -0.2896707

sample estimates:

mean of x mean of y

3.623074 3.926851

Como p-value deu menor que 0.05, então rejeita-se H0 e acata-se a hipótese alternativa, ou seja, erro2 realmente é significativamente menor que erro3 e, portanto, o modelo1 é melhor.

#Comparando erro 2 e erro 4:

```
> t.test(ErroAbsoluto2, ErroAbsoluto4, alternative = "two.sided")
```

Welch Two Sample t-test

data: ErroAbsoluto2 and ErroAbsoluto4

t = -80.369, df = 97.063, p-value < 2.2e-16

alternative hypothesis: true difference in means is not equal to 0

95 percent confidence interval:

-0.6927276 -0.6593384

sample estimates:

mean of x mean of y

3.623074 4.299107

Como p-value deu menor que 0.05, então rejeita-se H0 que os erros 2 e 4 são iguais, acatando-se H1 que são diferentes. Em sendo diferentes, vejamos qual dos dois é menor:

```
> t.test(ErroAbsoluto2, ErroAbsoluto4, alternative = "less")
```

Welch Two Sample t-test

data: ErroAbsoluto2 and ErroAbsoluto4

t = -80.369, df = 97.063, p-value < 2.2e-16

alternative hypothesis: true difference in means is less than 0

95 percent confidence interval:

-Inf -0.6620637

sample estimates:

mean of x mean of y

3.623074 4.299107

Como p-value deu menor que 0.05, então rejeita-se H0 e acata-se a hipótese alternativa, ou seja, erro2 realmente é significativamente menor que erro4 e, portanto, o modelo 1 é melhor.

```
> t.test(ErroAbsoluto3, ErroAbsoluto4, alternative = "two.sided")
```

Welch Two Sample t-test

data: ErroAbsoluto3 and ErroAbsoluto4

t = -41.856, df = 97.97, p-value < 2.2e-16

alternative hypothesis: true difference in means is not equal to 0

95 percent confidence interval:

-0.3899052 -0.3546064

sample estimates:

mean of x mean of y

3.926851 4.299107

Como p-value deu menor que 0.05, então rejeita-se H0 que os erros 3 e 4 são iguais, acatando-se H1 que são diferentes. Em sendo diferentes, vejamos qual dos dois é menor:

```
> t.test(ErroAbsoluto3, ErroAbsoluto4, alternative = "less")
```

Welch Two Sample t-test

data: ErroAbsoluto3 and ErroAbsoluto4

t = -41.856, df = 97.97, p-value < 2.2e-16

alternative hypothesis: true difference in means is less than 0

95 percent confidence interval:

-Inf -0.3574872

sample estimates:

mean of x mean of y

3.926851 4.299107

Como p-value deu menor que 0.05, então rejeita-se H0 e acata-se a hipótese alternativa, ou seja, erro3 realmente é significativamente menor que erro4 e, portanto, o modelo 2 é melhor.

#Análise de Variância (ANOVA):

```
> dados_anova = aov(base$PE~base$AT+base$AP)
```

```
> summary(dados_anova)
```

Df	Sum Sq	Mean Sq	F value	Pr(>F)
----	--------	---------	---------	--------

base\$AT	1	2505095	2505095	86688.5 <2e-16 ***
----------	---	---------	---------	--------------------

base\$AP	1	5196	5196	179.8 <2e-16 ***
----------	---	------	------	------------------

Residuals	9565	276406	29	
-----------	------	--------	----	--

Signif. codes: 0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Utilizando a ANOVA é possível obter as seguintes conclusões:

- Tem-se que existe uma diferença de produção de energia entre temperatura com nível de confiança de 99%;
- Tem-se que existe uma diferença de produção de energia entre pressão com nível de confiança de 99%;